SuperMimic：利用单一可微世界模型扩展人形机器人全身控制

Qiayuan Liao、Yiyang Shao＊、Junfeng Long＊、Kevin Zakka、Roberto Horowitz、Pieter Abbeel†、Koushil Sreenath†

加利福尼亚大学伯克利分校

项目主页：https://supermimic.github.io

arXiv:2610.28480v1 [cs.RO]，2026 年 10 月 20 日。

＊共同贡献。†共同指导。

第十届机器人学习会议（CoRL 2026），美国得克萨斯州奥斯汀。

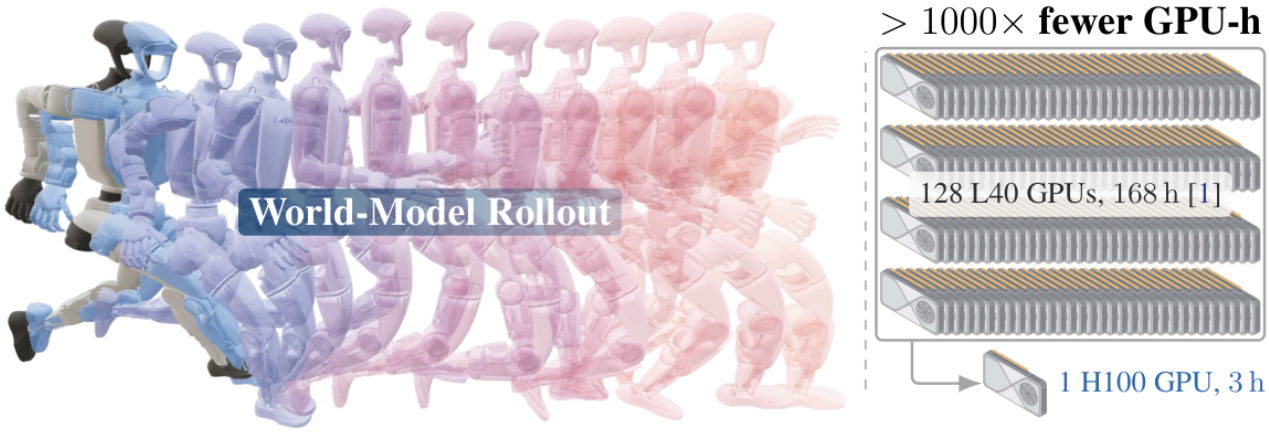


图 1：学习得到的可微世界模型用于训练人形机器人全身控制器，相较于集群规模的无模型强化学习，GPU 小时数减少超过 1000 倍（第 4.1 节）。 左：策略通过世界模型中的想象滚动展开得到改进。右：SONIC [1] 使用 128 块 L40 GPU 训练 168 小时，本文方法则使用一块 H100 GPU 训练 3 小时。

摘要

跟踪大规模人体运动数据集已成为实现通用、表现力丰富的人形机器人全身控制的主要途径，但将其扩展至大量运动的代价很高。现有流程采用无模型强化学习，或通过有损蒸馏合并针对单个运动训练的专用策略，或依靠集群规模的计算资源直接训练单一策略。SuperMimic 使用一个可微世界模型描述所有运动共享的动力学，从而在所有运动之间摊薄学习成本；该模型利用标准刚体仿真器记录的状态转移进行拟合。世界模型与跟踪策略在同一循环中共同训练，通过对短时域想象滚动展开进行随时间反向传播，获得策略的解析梯度。快速的想象滚动展开与解析梯度使策略学习更加高效。在单块 GPU 上训练 3 小时后，SuperMimic 的回报便超过了使用 128 块 GPU 训练 7 天的先进动作跟踪基线。其 GPU 小时数减少超过 1000 倍，在 129,514 个基准运动中仅有 25 个失败，而基线失败 179 个。在两块 GPU 上训练 9.8 小时后，SuperMimic 实现零失败。当运动数据从 1 小时增加至 264 小时时，世界模型的预测误差保持稳定，达到目标回报所需的 GPU 小时数仅缓慢增长。我们的策略能够迁移至真实 Unitree G1 机器人，执行多种运动和高难度技巧动作。SuperMimic 消除了计算资源在人形机器人全身控制扩展中的瓶颈，使得实际测量动作跟踪的缩放规律成为可能。

关键词： 人形机器人、全身控制、基于模型的强化学习。

> **中文译本说明：** 本译本完整覆盖原 PDF 的正文、致谢、附录和图表说明，章节、公式、图表与参考文献编号沿用原文。图表保留原始图像及图内英文标注，图注与表格文字译为中文；参考文献保留原始书目信息。为便于连续阅读，部分浮动图表调整到相应段落附近。原文：SuperMimic: Scaling Humanoid Whole-Body Control with One Differentiable World Model，arXiv:2610.28480v1。

1 引言

人形机器人有望在人类设计的环境中工作，但这要求全身控制器能够覆盖多样化的人体运动，从行走、舞蹈到下蹲和平衡恢复。基于物理的运动模仿通过训练强化学习策略来跟踪参考动作片段 [2]，以应对这一需求；这些片段来自大规模运动捕捉（mocap）数据集 [1]。现有系统通过两种方式扩展这一思路：将大量针对单个片段的专家策略蒸馏到一个控制器中 [3]，或者直接在大型动作库上训练通用策略 [1]。在这两种情况下，更丰富的动作库都能产生能力更强的控制器。然而，随着运动覆盖范围扩大，两种方式的计算成本都会大幅增加。例如，先进的跟踪器 SONIC [1] 使用 128 块 GPU 训练约 168 小时，总计约 21,000 GPU 小时。虽然参考动作各不相同，但它们共享同一套人形机器人混合刚体动力学。无模型强化学习未显式建模这一共享结构，而是反复利用带噪声的仿真滚动展开估计动作的后果。因此，扩展至更多运动实际上就意味着增加计算资源。

SuperMimic 利用一个从仿真器所记录的状态转移中学习得到的可微世界模型，解决这一效率问题。通过对短时域想象滚动展开进行随时间反向传播（BPTT），可以经由学习模型获得解析策略梯度，使一个动力学模型得以在整个运动捕捉库之间摊薄学习成本。这些梯度来自学习模型，而非对仿真器直接求导，因此 SuperMimic 能兼容刚体仿真器，包括具有非光滑接触和不可微实现的仿真器。

在单块 GPU 上，SuperMimic 在 3 小时内就超过了 SONIC 已发布检查点的归一化回报，并将 GPU 小时数减少超过 1000 倍（第 4.1 节）。在包含 129,514 个运动的基准上，SuperMimic 使用单块 GPU 训练 3 小时后有 25 个运动失败，使用两块 GPU 训练 9.8 小时后没有运动失败，而 SONIC 已发布检查点有 179 个运动失败（附录 F）。当数据集时长增加 264 倍时，世界模型的预测误差保持稳定，SuperMimic 达到固定回报所需的计算量仅缓慢增加。学习得到的策略能够迁移至真实 Unitree G1 机器人。在针对下游接口的初步研究中，使用强化学习训练的速度编码器优于蒸馏基线。

贡献。

- **用于可部署人形机器人控制的基于模型强化学习（MBRL）。** 我们证明，在长期由无模型近端策略优化（PPO）[4] 主导的设定中，通过学习得到的可微世界模型进行 BPTT，可以训练全身跟踪策略，而且所得控制器能够迁移至真实 Unitree G1 机器人。
- **计算不再是扩展的瓶颈。** SuperMimic 在单块 GPU 上超过了集群规模 PPO 流程 SONIC 的回报，GPU 小时数减少超过 1000 倍（第 4.1 节）。随着动作库扩大，其训练成本仅缓慢增加，使得无需庞大的 GPU 基础设施也能切实扩展人形机器人全身控制。
- **分析性能提升背后的关键因素。** 我们确定了降低计算成本的世界模型的三个性质：在数据集时长增加 264 倍时预测误差保持稳定；滚动展开比仿真器快 10 倍以上；以及解析梯度，借助解析梯度，策略达到在世界模型上训练的 PPO 的最佳回报时，所需的想象步数约减少 64 倍。
- **超越蒸馏、以强化学习训练下游控制。** 作为初步研究，同一个学习得到的世界模型利用接口自身的任务奖励来训练下游目标编码器。对于速度指令，采用该编码器的策略比蒸馏基线跟踪得更准确。

2 相关工作

大规模基于物理的动作跟踪。 基于物理的运动模仿学习能够在接触丰富的刚体动力学下复现参考动作的控制器。DeepMimic [2] 通过无模型强化学习展示了表现力丰富的角色技能，PHC [11] 则将这一范式扩展至大型运动集合，并具备稳健的恢复能力。SONIC [1] 进一步证明，扩大运动数据、策略容量和训练计算量，可以得到能够迁移至人形机器人硬件的通用控制器。这些结果表明，动作跟踪是广泛覆盖全身行为的一条可行途径。然而，训练这些大规模动作跟踪器需要大量仿真滚动展开和可观的计算资源。SuperMimic 通过学习一个由所有运动共享的可微动力学模型，解决这一瓶颈，使策略改进能够利用解析梯度，而不必依靠无模型滚动展开的估计。

方法	模仿阶段	潜在表征阶段	下游阶段	任务信号	真实机器人
NPMP [5]	SVG(0)	BC	SVG(0)	RL	否
ControlVAE [6]	MBRL	MBRL	MBRL	RL	否
PhysicsVAE [7]	PPO	BC[1]	PPO	RL	否
PULSE [8]	PPO	DAgger	PPO	RL	否
MaskedMimic [9]	A2C	DAgger	DAgger	蒸馏	否
BeyondMimic [3]	PPO	DAgger	CGD	蒸馏	是
SONIC [1]	PPO	PPO	PPO	蒸馏[2]	是
LATENT [10]	PPO	DAgger	PPO	RL	是
SuperMimic	MBRL	MBRL	MBRL	蒸馏／RL	是

表 1：不同方法及其各阶段训练策略的比较。 模仿、潜在表征和下游三列表示各阶段采用的训练策略。任务信号指用于训练下游接口的信号：接口自身的任务奖励（RL），或参考跟踪信号（蒸馏）。原表中合并单元格表示相关阶段联合训练，相邻而未合并的单元格表示顺序训练，即冻结前一阶段后再训练后一阶段。本译表用重复策略名称表示原表的合并单元格，具体联合关系为：ControlVAE 的模仿与潜在表征阶段联合训练；MaskedMimic 的潜在表征与下游阶段联合训练；SONIC 和 SuperMimic 的三个阶段均联合训练。其余相邻阶段按顺序训练。

SVG(0)：随机价值梯度；BC：在固定专家滚动展开上进行离线行为克隆，与 DAgger 使用学生策略滚动展开不同；CGD：分类器引导扩散；A2C：优势策略—价值方法；DAgger：数据集聚合。[1]行为克隆中加入一个经由冻结的已学习动力学模型计算的单步下一状态一致性项。[2]目标编码器与跟踪器使用动作跟踪奖励和潜在表征对齐损失联合训练，不使用任务特定奖励。

用于运动控制的已学习可微动力学。 SuperTrack [12] 通过一个学习得到的可微仿真器替代模型来优化运动控制策略。ControlVAE [6] 联合学习动力学模型、潜在技能表征和生成式控制器，而 MoConVQ [13] 将基于学习模型的训练扩展至使用数十小时数据的离散运动表征。SuperDyno [14] 将可微神经动力学扩展至数万个动作片段。这些方法证明了已学习动力学与解析策略梯度在可扩展仿真角色控制中的有效性。SuperMimic 将这一方向推进至单 GPU 大规模人形机器人跟踪器训练及其仿真到现实部署：世界模型以仿真上下文为条件，而部署的策略网络使用带噪声的本体感知观测和目标输入（第 3.2 节）。我们评估了模型精度、滚动展开吞吐量和可微策略更新对训练效率的贡献，以及预测误差如何随运动覆盖范围扩大而变化（第 4.1—4.2 节），并展示了所得控制器的真实机器人部署（第 4.4 节）。

基于模型的策略优化与机器人部署。 Dreamer [15] 和 DreamerV3 [16] 学习潜在动力学，用于基于想象的策略—价值学习；TD-MPC [17] 则将短时域规划与末端价值预测结合。DayDreamer [18] 展示了直接在真实机器人上学习世界模型。SHAC [19] 利用可微仿真进行短时域策略—价值更新，启发了 SuperMimic 通过价值网络进行自举的目标函数。基于解析梯度的机器人控制也可以将简化的可微替代模型与高保真正向仿真器结合，已有四足机器人运动控制工作对此进行了展示 [20]。SuperMimic 从仿真器状态转移中学习其替代模型，并通过短时域想象滚动展开反向传播，同时保持对标准刚体仿真器的兼容性。

RWM [21] 和 RWM-U [22] 表明，在学习得到的神经仿真器中训练的策略能够迁移至真实机器人。二者均在想象滚动展开上利用 PPO 优化策略；RWM-U 还采用带不确定性惩罚的离线优化。SuperMimic 则通过对学习得到的动力学中的回报求导来优化策略。RWM 和 RWM-U 使用其他策略生成的轨迹预训练世界模型。相比之下，SuperMimic 在训练过程中，使用自身策略收集的数据拟合世界模型。

可复用运动表征与下游控制。 可复用控制器将动作跟踪与下游目标接口连接起来（表 1）。NPMP [5] 和 PhysicsVAE [7] 从专家行为中学习潜在运动表征；PULSE [8] 和 LATENT [10] 利用已学习运动表征进行下游强化学习。MaskedMimic [9] 通过运动补全支持局部身体和多模态目标，BeyondMimic [3] 则通过引导扩散实现目标跟随。SONIC [1] 使用跟踪奖励和潜在表征对齐损失，将目标编码器与其跟踪器联合训练。ControlVAE [6] 在冻结技能控制器的同时，通过其学习模型优化下游任务策略。SuperMimic 通过同一个动力学模型，联合训练针对各类目标的编码器与一个共享解码器（附录 B）。目标接口既可以优化参考跟踪奖励，也可以优化其自身的任务奖励。我们的初步研究将速度接口与动作跟踪接口同时训练，分别使用这两种目标各进行一次实验（第 4.5 节）。

3 方法

3.1 SuperMimic 训练循环

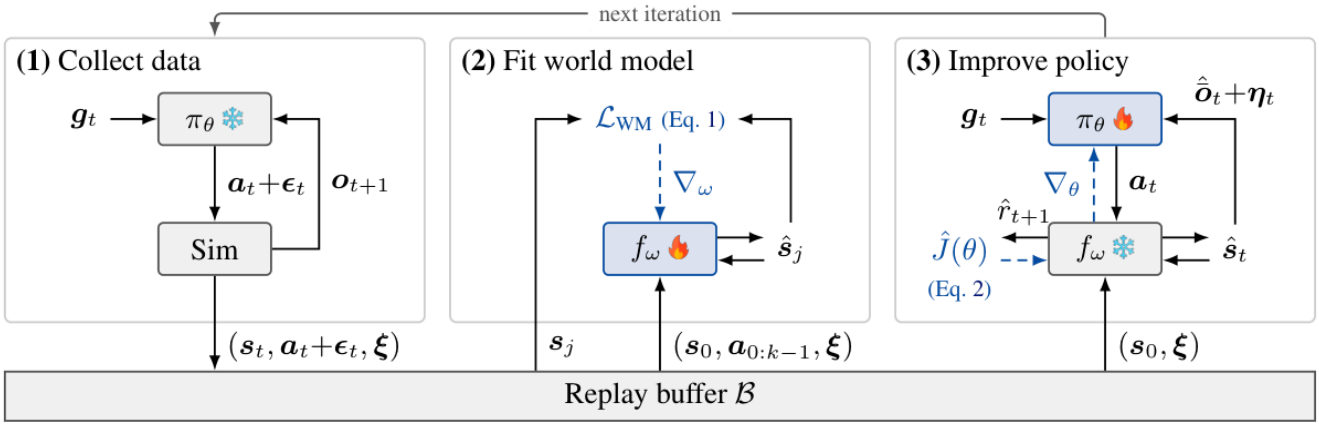


图 2：SuperMimic 训练循环。 （1）当前策略 π_θ 在仿真中收集状态转移，存入固定大小的经验回放缓冲区 $\mathcal{B}$，新状态转移替换最旧的状态转移。（2）利用从 $\mathcal{B}$ 中采样的 k 步窗口拟合可微世界模型（第 3.2 节）。（3）在冻结的世界模型中进行 H 步想象滚动展开，并通过 BPTT 改进策略；在同一阶段训练的价值网络 V_ψ 对 H 步之后的回报进行自举估计（第 3.3 节）。虚线箭头表示梯度；雪花图标表示冻结，火焰图标表示训练。符号：目标 g_t（例如参考动作）、动作 a_t、动作噪声 ϵ_t、观测 o_t、状态 s 与预测状态 $\hat{s}$，以及仿真上下文 ξ（域随机化参数）。L_{WM} 为世界模型损失，$\hat{o}_t$ 为预测的无噪声观测，η_t 为传感器噪声，$\hat{r}_{t+1}$ 为预测奖励，$\hat{J}(\theta)$ 为策略目标。

SuperMimic 在包含多种技能的动作库上训练一个以目标为条件的全身控制器，并支持多个目标接口。它通过可微世界模型捕获人形机器人共享的动力学，并通过短时域想象滚动展开改进策略。训练在同一个循环中交替进行三个阶段（图 2）。首先，当前策略收集仿真器状态转移并存入经验回放缓冲区。其次，使用短回放窗口拟合可微世界模型。第三，通过冻结的世界模型对想象回报进行反向传播以改进策略；每次滚动展开都以 Dyna 风格 [23, 24] 从回放缓冲区中的状态出发。缓冲区、模型与策略在整个训练过程中持续更新，因此动力学学习与控制是共同改进的，而不是分为不同阶段（算法 A.1、附录 D）。早期策略生成的状态转移仍可用于拟合世界模型，因为动力学与收集这些状态转移的策略无关。

我们用 $\mathcal{M}$ 表示以目标为条件的部分可观测马尔可夫决策过程（POMDP），并采用简洁记号，分别用 s_t、g_t 和 a_t 表示状态、目标和动作。状态 s_t 决定本体感知观测 o_t 和终止标记 d_t；若 s_t 为终止状态，则 $d_t = 1$。在状态 s_t 下执行动作 a_t，得到奖励 r_{t+1} 和下一状态 s_{t+1}。策略是确定性的，即 $a_t = \pi_\theta(o_t, g_t)$，其中 a_t 参数化归一化的关节目标位置；对于动作跟踪，g_t 从参考动作中读取。

在数据收集过程中，仿真器执行带噪声的动作 $a_t + \epsilon_t$，其中动作噪声 $\epsilon_t \sim \rho_\epsilon$，回放缓冲区存储这一实际执行的带噪声动作。该噪声扩大了世界模型拟合所覆盖的动作范围；它只服务于模型拟合，并且是可选的。回报采用软存活权重，$c_0 = 1$，$c_{t+1} = c_t(1 - d_{t+1})$，从而有 $J(\theta) = \mathbb{E}[\sum_{t\geq 0} \gamma^t c_t r_{t+1}]$，其中折扣因子 $\gamma \in [0, 1)$。仿真器记录硬终止标记，而学习模型预测终止概率 $\hat{d}_t \in [0, 1]$，使想象滚动展开中的存活权重保持可微。全文中，帽号表示仿真器量在世界模型中的对应量。我们还将观测分解为 $o_t = \bar{o}_t + \eta_t$，其中 $\bar{o}_t$ 是无噪声观测，已知的观测噪声 $\eta_t \sim \rho_\eta$ 在世界模型之外采样。完整空间和奖励见附录 A。

默认接口是完整参考动作跟踪。其他目标接口（例如速度接口）共享同一个已学习动力学，并与动作跟踪共同训练（附录 B）。

3.2 学习可微世界模型

仿真器的关节式多刚体动力学是已知的，但仿真器不必提供梯度，因此 SuperMimic 学习一个可微替代模型来获得策略梯度：它为第 3.3 节的 BPTT 更新提供预测值和雅可比矩阵。所得解析策略梯度，是仿真期望回报的某个替代目标的梯度。由于仿真器随机性的来源已知，世界模型保持确定性：它以每个回合的仿真上下文 ξ（摩擦、标定偏移以及躯干质心）为条件，并预测无噪声观测 $\bar{o}_t$。

世界模型包含一个学习得到的动力学模型，以及奖励、观测和终止输出头；各输出头或通过学习得到，或通过解析计算得到：

$$\begin{aligned} \hat{s}_{t+1} &= f_\omega(\hat{s}_t, a_t, \xi), \quad \hat{r}_{t+1} = r_\omega(\hat{s}_t, a_t, g_t), \\ \hat{\bar{o}}_t &= g_\omega(\hat{s}_t, \xi), \qquad \hat{d}_t = d_\omega(\hat{s}_t, g_t). \end{aligned}$$

我们在 k 步自回归回放窗口上拟合网络权重 ω（$k = 8$），以记录状态 $\hat{s}_0 = s_0$ 为初始状态，按照记录的动作向前滚动展开，并最小化：

$$L_{\mathrm{WM}}(\omega) = \mathbb{E}_{\mathcal{B}} \sum_{j=1}^{k} \left[\|\hat{s}_j - s_j\|^2 + (\hat{r}_j - r_j)^2 + \|\hat{\bar{o}}_j - \bar{o}_j\|^2 + \mathrm{BCE}(\hat{d}_j, d_j) \right]. \tag{1}$$

其中，通过解析计算得到的输出头没有对应的损失项。r_j 是仿真器奖励，$d_j \in \{0, 1\}$ 是仿真器终止标签，BCE 为二元交叉熵。

3.3 通过世界模型学习策略

每次策略更新时，我们固定世界模型权重 ω，在 $H = 32$ 步的想象滚动展开上优化 π_θ 和 V_ψ。价值网络 V_ψ 估计第 H 步之后的回报，因此模型只需要在这 H 步内保持准确。这一想象时域长于拟合模型时使用的 k 步回放窗口（第 3.2 节）。在实际中，学习模型在任意长的滚动展开中都能保持稳定，因为 k 步自回归拟合训练了它纠正自身预测误差的能力。

每次想象滚动展开都从回放缓冲区状态 $s_0 \sim \rho_0$ 及其记录的仿真上下文 ξ 出发。在第 t 步，模型输出 $\hat{\bar{o}}_t$，我们重新加入传感器噪声，然后策略执行动作：$a_t = \pi_\theta(\hat{\bar{o}}_t + \eta_t, g_t)$，其中 $\eta_t \sim \rho_\eta$。想象滚动展开上的策略目标为：

$$\hat{J}(\theta) = \mathbb{E}_{s_0 \sim \rho_0,\, \pi_\theta} \left[\sum_{t=0}^{H-1} \gamma^t \hat{c}_t \hat{r}_{t+1} + \gamma^H \hat{c}_H V_\psi(\hat{s}_H, g_H, \xi) \right]. \tag{2}$$

对于动作跟踪，奖励 r_{t+1} 采用 BeyondMimic 的动作跟踪奖励 [3]，但去掉了其中的自碰撞惩罚（附录 A）。

世界模型可微，因此 BPTT 能通过世界模型相对于 $\hat{s}_t$ 和 a_t 的雅可比矩阵，在 H 个想象步中计算一阶梯度 $\nabla_\theta \hat{J}$。相比之下，PPO 将动力学视为黑箱：用采样动作的优势对随机策略的得分函数 $\nabla_\theta \log \pi_\theta$ 加权，得到似然比估计。BPTT 则直接对回报关于各个动作求导，因此在短时域内，其梯度的方差要低得多。

价值网络 V_ψ 拟合广义优势估计（GAE）回报 [25]；这些回报仅根据想象状态转移沿时间反向计算：

$$
\begin{aligned}
L_V(\psi) &= \mathbb{E} \sum_{t=0}^{H-1} (V_t - \hat{R}_t)^2, \\
\hat{R}_t &= \hat{r}_{t+1} + \gamma(1 - \hat{d}_{t+1}) \left[(1-\lambda) V_{t+1} + \lambda \hat{R}_{t+1} \right].
\end{aligned}
\tag{3}
$$

其中 $V_t = V_\psi(\hat{s}_t, g_t, \xi)$。递推从 $\hat{R}_H = V_H$ 开始，即价值网络对时域之外回报的估计。每次滚动展开只计算一次目标 $\hat{R}_t$，拟合 ψ 时这些目标保持固定。

策略与价值网络的更新共同构成一种短时域策略—价值方法，其思路与 SHAC [19] 一致；SHAC 通过可微仿真器进行反向传播。SuperMimic 用存活权重 $\hat{c}_t$ 取代了 SHAC 中回合的硬终止，并且其价值网络不使用指数移动平均目标网络。此前利用解析梯度训练的动作跟踪控制器往往省略价值网络，只优化 H 步奖励之和 [12, 6]。不使用价值网络时，训练也可以达到相近的常规跟踪回报，但这种不进行自举的目标更为短视。价值网络在受到扰动后尤为重要，因为恢复或平衡的奖励可能位于想象时域之外（第 4.3 节）。

4 实验结果

我们展示 SuperMimic 相比 PPO 流程具有更好的扩展表现，分析支撑这一表现的世界模型特性，在真实 Unitree G1 上演示迁移，并报告对下游目标接口的初步研究。仿真器采用 MuJoCo 的 GPU 实现 MuJoCo Warp [26]。本文报告的所有计算成本均在 Lambda 按需实例的 NVIDIA H100（80 GB SXM5）GPU 上测量。我们使用了多个随机种子，发现训练非常稳定，并将其归因于动作跟踪在每一步提供的稠密奖励。因此，图中未报告不同随机种子之间的变化。归一化回报（下文简称“回报”）是整个回合中逐步奖励的无折扣总和，除以该总和能够达到的最大值。因此，提前终止的策略得分较低。

4.1 SuperMimic 以远少于 SONIC 的 GPU 小时达到同等跟踪水平

我们与 SONIC 进行比较。SONIC 是已发表的 PPO 流程，在一个包含 128 张 GPU 的集群上训练。两种方法均基于 BeyondMimic 的动作跟踪建模方式 [3]，因此 SONIC 是现有已发表方法中最接近的比较对象。在单张 GPU 上训练不超过 3 小时，SuperMimic 就超过了 SONIC 已发布检查点的归一化回报（图 3(a)）。在包含 129,514 个动作的共同基准上，其失败动作数也少于 SONIC：单张 GPU 训练 3 小时后为 25 个，两张 GPU 训练 9.8 小时后为 0 个，而 SONIC 已发布检查点为 179 个（附录 F）。3 小时是一个保守的表述：从这一时刻起，在回报和失败动作数两项指标上，每个检查点领先 SONIC 的幅度，都至少达到 SONIC 与 SuperMimic 最佳结果之间差距的一半。因此，SuperMimic 的墙钟时间少于 SONIC 的 1/50，GPU 小时少于其 1/1000。

计算成本核算。 上述比例比较的是 SONIC 报告的 128 张 NVIDIA L40 GPU 训练 7 天（约 21,000 GPU 小时），以及一张 NVIDIA H100 训练 3 小时；在这 3 小时内，SuperMimic 已超过 SONIC 已发布检查点的回报。两者在墙钟时间上的差距约为 56 倍（> 50 倍），在 GPU 小时上的差距约为 7200 倍（> 1000 倍）。这 3 小时涵盖完整训练循环；检查点评估在训练后进行，不计入其中。SuperMimic 使用 BONES-SEED [27] 中 264.56 小时的动作进行训练，该数据是 SONIC 数据的公开子集，时长约为 SONIC 所用 611 小时的 1/2.3。GPU 型号也不同：按峰值吞吐量计算，H100 的 fp32 性能是 L40 的 0.74 倍，张量核心性能是其 5.5 倍；两次训练实际使用了多少峰值性能尚不清楚。尽管如此，2.3 倍的数据差异，以及至多 5.5 倍的 GPU 峰值吞吐量差异，都不足以解释 GPU 小时上 1000 倍的差距。

图 4(a) 给出了在 LAFAN1 [28] 上的受控比较。基线 PPO-Sim 是在仿真器中训练的 PPO。PPO-Sim 与 SuperMimic 使用相同的动作、观测、奖励、终止条件、域随机化、策略网络与价值网络规模，以及评估协议。它使用 BeyondMimic 的 PPO 超参数 [3]，每张 GPU 运行 8192 个并行环境，是 SuperMimic 的两倍。PPO-Sim 从采样得到的仿真器滚动展开中估计策略梯度；SuperMimic 则通过世界模型滚动展开，对想象回

报进行反向传播。SuperMimic 在单张 GPU 上训练不超过 1.2 小时，评估回报就达到 0.82。PPO-Sim 在 18 小时预算内未达到这一水平。它的最终回报在一张 GPU 上为 0.60，四张 GPU 上为 0.70，八张 GPU 上为 0.72，因此从四张增加到八张 GPU 几乎没有帮助。

图 3(b, c) 表明，对于 SuperMimic，随着数据集时长增加，达到目标回报所需的 GPU 小时增长缓慢；在同一组数据集规模扫描中，世界模型的预测误差保持稳定。第 4.2 节将这两种趋势归因于一个世界模型对所有动作共享动力学的学习摊销。

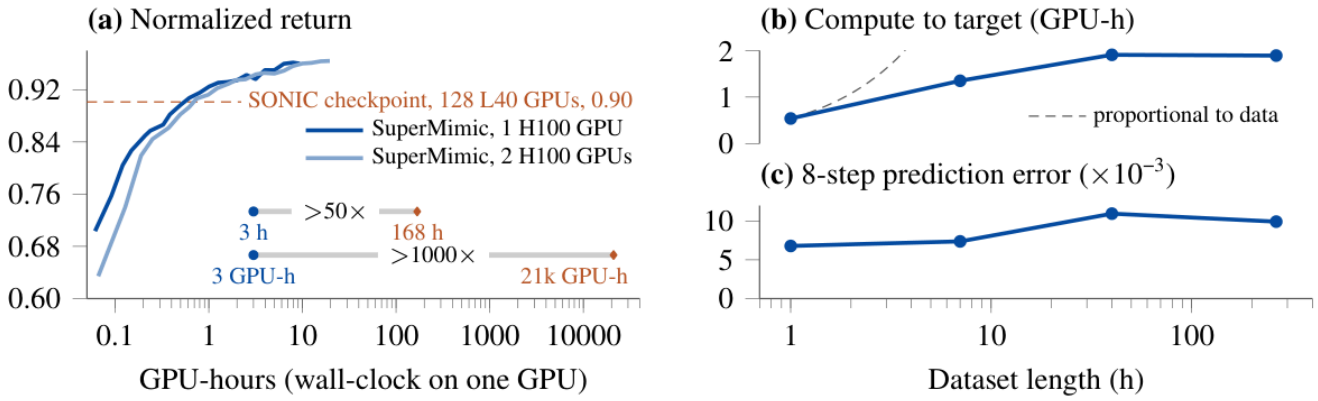


图 3：SuperMimic 以远少于 SONIC 的 GPU 小时超过其跟踪回报。 (a) 在一张和两张 H100 GPU 上训练的 SuperMimic，均超过 SONIC 已发布检查点（虚线）的回报；三者均在同一个包含 129,514 个动作（264 小时）的基准上评分。两行计算预算比较了 SuperMimic（圆点）与 SONIC（菱形）：SuperMimic 将墙钟时间减少到原来的 1/50 以下，将 GPU 小时减少到原来的 1/1000 以下。(b, c) 在同一组数据集时长扫描中，达到目标回报所需的 GPU 小时 (b) 增长缓慢，而当数据集从 1 小时增长到 264 小时时，世界模型的 8 步预测误差 (c) 保持在 0.007—0.011 之间；这与一个世界模型对所有动作共享的身体与接触动力学进行学习摊销的解释一致。预测误差仅计入状态，按预先定义的标称误差进行归一化，并在策略滚动展开上在线测量。

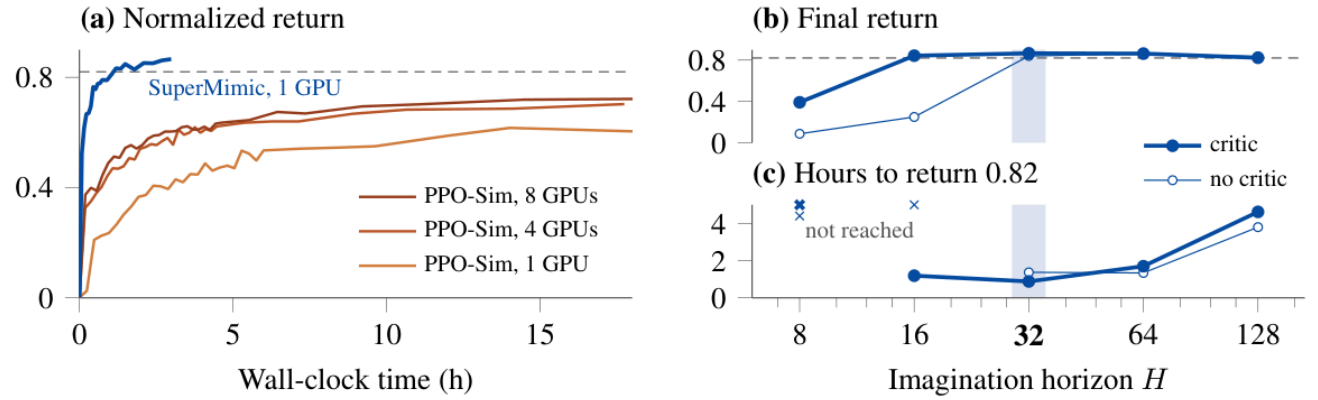


图 4：在受控比较中，SuperMimic 比 PPO-Sim 更快达到更高回报，价值网络则使更短的想象时域成为可能。 所有实验均使用 LAFAN1（40 个片段，2.45 小时）。(a) SuperMimic 在单张 GPU 上通过世界模型对想象回报进行反向传播；PPO-Sim 则在 1、4 或 8 张 GPU 上，在仿真器中运行 PPO（第 4.1 节）。曲线上的每个点都是一个已保存检查点在全部 40 个片段上的评分。(b, c) 不同想象时域 H 下，使用或不使用价值网络时的最终训练回报 (b)，以及训练回报达到 0.82 所需的墙钟小时数 (c)。(a) 和 (b) 中的虚线表示目标回报 0.82。训练回报是训练回合的回报。这些回合的初始状态遵循基于回报的重置采样（附录 D.1），并在训练过程中发生变化，因此训练回报不同于 (a) 中的检查点评分。(c) 中的叉号表示该时域下未达到回报 0.82：$H = 8$ 时的两种设置，以及 $H = 16$ 时不使用价值网络的设置。阴影带表示默认的 $H = 32$。

4.2 所学世界模型的特性

上述结果依赖于所学世界模型 f_ω 的三个特性：动作库扩大时仍保持精度，滚动展开速度快，并且可微。

一个模型摊销整个动作库的学习成本。 在图 3(c) 中，当数据集从 1 小时增长到 264 小时时，世界模型的 8 步预测误差保持在 0.007 到 0.011 之间。所有动作都由同一个人形机器人执行，因此新增片段为共享的身体与接触动力学提供了更多证据，而不要求新增模型容量。这与达到目标回报所需计算量增长缓慢的现象一致（第 4.1 节）。

想象加速滚动展开。 策略优化期间，滚动展开速度决定更新成本。图 5(a) 表明，在实际使用的批量大小下，世界模型的运行速度超过 MuJoCo Warp 的 10 倍；当并行环境数达到 64k 时，最高达到 62 倍。

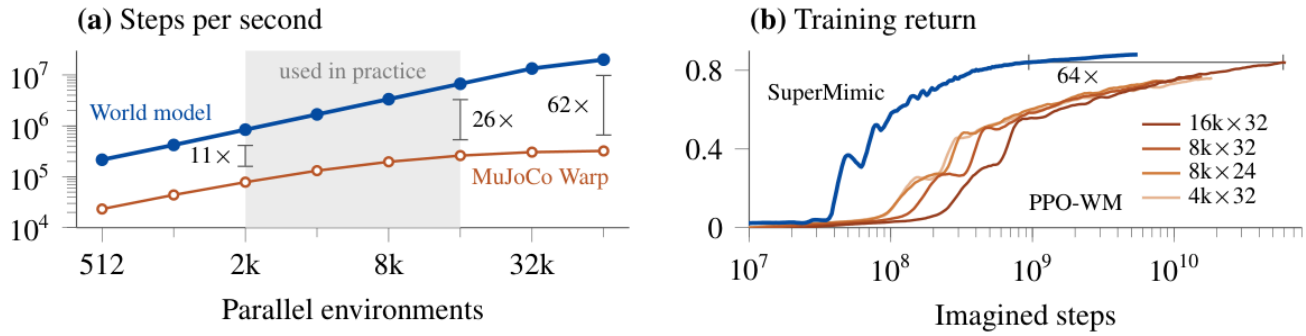


图 5：想象滚动展开既快速又可微。 (a) 在一张 H100 上，在实际使用的批量大小范围内（阴影区域，2k—16k 个并行环境），世界模型的运行速度超过 MuJoCo Warp 的 10 倍；到 64k 时，MuJoCo Warp 的吞吐量已趋于平坦，两者差距扩大到 62 倍。一步指一个 50 Hz 控制步，MuJoCo Warp 将其计算为四个 5 ms 子步；世界模型使用 SuperMimic 训练时的 TF32 精度。(b) 在 LAFAN1 [28] 的行走、跑步和冲刺动作上，采用策略—价值更新训练的 SuperMimic，仅需约 1/64 的想象步数，就达到在世界模型滚动展开上训练的 PPO（PPO-WM）的最佳训练回报。PPO-WM 使用四种批量大小（并行滚动展开数 × 每次滚动展开步数）；16k × 32 的效果最好。每条曲线都采用以想象步数的对数尺度上 ±0.05 个十进数量级为窗口的居中移动平均。

一阶梯度需要更少的想象步数。 作为机制消融实验，图 5(b) 单独考察了一阶策略更新的作用：SuperMimic 仅需约 1/64 的想象步数，就达到 PPO-WM 的最佳回报，因此收益不只来自滚动展开速度。

4.3 价值网络支持更短时域与受推恢复

图 4(b, c) 扫描了使用和不使用价值网络时的 H。不使用价值网络时，$H \leq 16$ 会训练失败。使用价值网络时，$H = 16$ 的表现可匹配不使用价值网络的 $H = 32$，而 $H = 32$ 最快达到回报 0.82。将 H 从 64 增加到 128 后，达到该回报的耗时接近原来的三倍，最终回报也有所降低；$H = 128$ 是单张 H100 显存可容纳的最长时域。即使回报相当，价值网络仍会改变行为。在仿真中保持静态 T 形姿态时，受到 0.5—4 m/s 的速度扰动后，带价值网络的策略在 0.5—2.4 秒内恢复稳定。不带价值网络的策略始终无法稳定下来：即使受到 0.5 m/s 扰动，也会持续踉跄，受到 4 m/s 扰动时则会跌倒。

4.4 向真实机器人迁移

同一个通用动作跟踪器无需针对单个动作调参，即可部署到真实 Unitree G1 上（图 6）。这四个动作涵盖移动动作（跳步跃起）、躯干和四肢接触地面的多接触全身动作（侧滚），以及特技动作（90° 翻转和原地 360° 翻转）。



图 6：通过所学世界模型训练的同一个通用动作跟踪器，可迁移到真实 Unitree G1。 (a) 跳步跃起，(b) 侧滚，(c) 90° 翻转，(d) 原地 360° 翻转。

4.5 下游任务：强化学习编码器与蒸馏基线

SuperMimic 将下游目标编码器与动作跟踪接口联合训练，共享同一个解码器和世界模型（附录 B）。我们对下游接口的研究仍处于初步阶段。我们通过世界模型，以速度跟踪奖励训练一个速度编码器，并将其与蒸馏基线比较：该基线速度编码器使用动作跟踪奖励训练，其指令从参考动作中读取。图 7 在覆盖速度空间的 672 个阶跃响应上评估两者（附录 G）。强化学习编码器在其中 650 个响应上的稳态误差更低，蒸馏编码器则在 15 个响应上更低。只有蒸馏编码器发生跌倒，出现在七个动作库中几乎没有数据覆盖的快速转弯指令上。

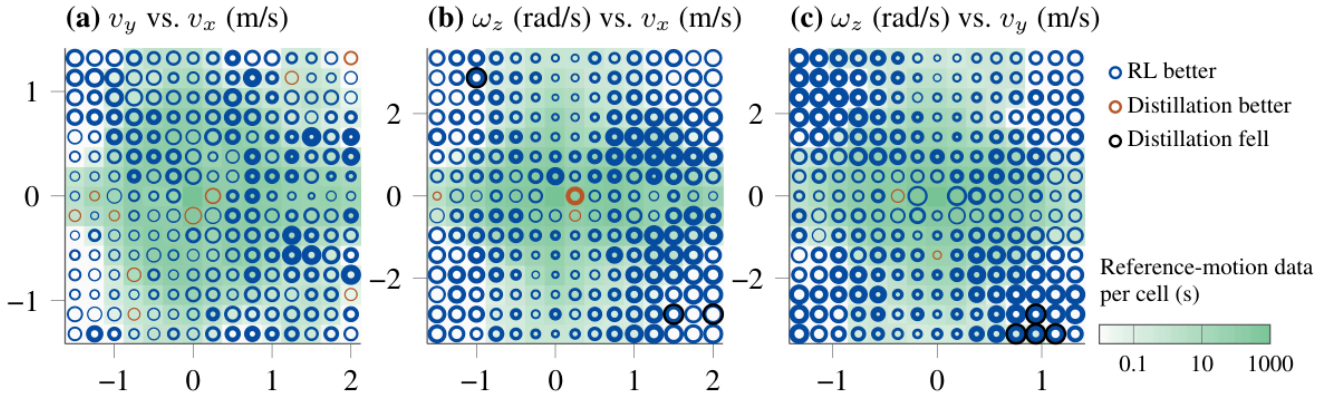


图 7：使用强化学习训练的速度编码器的策略，比蒸馏基线更准确地跟踪阶跃指令。 每个子图都是指令空间中第三个分量为零的一个平面，每个圆环代表一条指令。外圆盘的面积正比于两个策略对该指令的阶跃响应相对稳态误差中的较大值，内孔面积正比于较小值；颜色标记表现更好的策略。详见附录 G。

5 结论

SuperMimic 消除了扩展人形机器人全身控制时的计算瓶颈。单个学习得到的可微世界模型刻画所有动作共享的动力学，通过该模型进行时间反向传播，将整个数据集的学习成本摊销到同一个策略上。该策略在单张 GPU 上训练，回报超过在 128 张 GPU 集群上训练的策略，并能迁移到真实 Unitree G1。在受控的数据集时长扫描中，其训练成本增长缓慢。同一个模型还能直接使用下游速度接口自身的任务奖励来训练该接口。现在，每次实验只需一张 GPU，就能以可负担的成本测量动作跟踪的缩放规律。

6 局限与未来工作

- **对多接口训练的研究仍不充分。** 我们同时训练速度编码器与动作跟踪器，但速度跟踪奖励仅更新速度编码器，不更新共享解码器（附录 B）。因此，这种并行训练等同于在动作跟踪器训练后再训练速度编码器，可能并非必要。若速度跟踪奖励也更新解码器，并行训练是否有益，尚未验证。
- **动力学仅来自仿真器。** 世界模型只从仿真器状态转移中学习。真实机器人数据可以进一步改进模型，其可微性也可以支持系统辨识。
- **不包含地形或物体交互。** SuperMimic 仅在平地上训练。将其扩展到地形和物体交互仍在进行中。

致谢

感谢 Bike Zhang、Sangli Teng、Nima Rahmanian 和 Songbo Hu 提供的有益讨论及实验帮助。本研究部分获得 Komatsu、BAIR 人形智能中心、Apple 和 RAI Institute 的支持。感谢 Lambda 为本项目赞助计算资源。动作数据由 Bones Studio（https://bones.studio/）提供。Pieter Abbeel 和 Koushil Sreenath 同时担任加利福尼亚大学伯克利分校教授及 Amazon Scholar。本文介绍的是在加利福尼亚大学伯克利分校完成的工作，与 Amazon 无关。

参考文献

以下保留原文书目信息，便于检索和对应引用。

[1] Z. Luo, Y. Yuan, T. Wang, C. Li, F. Castañeda, S. Chen, Z.-A. Cao, J. Li, D. Minor, Q. Ben, J. Park, D. Sami, Z. Wang, X. Da, R. Ding, C. Hogg, L. Song, E. Lim, E. Jeong, T. He, H. Xue, W. Xiao, S. Yuen, J. Kautz, Y. Chang, U. Iqbal, L. Fan, and Y. Zhu. SONIC: Supersizing motion tracking for natural humanoid whole-body control. Science Robotics, 11(117):eaed4592, 2026. doi:10.1126/scirobotics.aed4592.

[2] X. B. Peng, P. Abbeel, S. Levine, and M. van de Panne. DeepMimic: Example-guided deep reinforcement learning of physics-based character skills. ACM Transactions on Graphics, 37 (4):143:1–143:14, 2018. doi:10.1145/3197517.3201311.

[3] Q. Liao, T. E. Truong, X. Huang, Y. Gao, G. Tevet, K. Sreenath, and C. K. Liu. BeyondMimic: From motion tracking to versatile humanoid control via guided diffusion. Science Robotics, 11(117):eadx8924, 2026. doi:10.1126/scirobotics.adx8924.

[4] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. Proximal policy optimization algorithms. arXiv preprint arXiv:1707.06347, 2017. URL https://arxiv.org/abs/1707.06347.

[5] J. Merel, L. Hasenclever, A. Galashov, A. Ahuja, V. Pham, G. Wayne, Y. W. Teh, and N. Heess. Neural probabilistic motor primitives for humanoid control. In International Conference on Learning Representations, 2019. URL https://openreview.net/forum?id=BJl6TjRcY7.

[6] H. Yao, Z. Song, B. Chen, and L. Liu. ControlVAE: Model-based learning of generative controllers for physics-based characters. ACM Transactions on Graphics (TOG), 41(6):1–16, 2022. doi:10.1145/3550454.3555434.

[7] J. Won, D. Gopinath, and J. Hodgins. Physics-based character controllers using conditional VAEs. ACM Transactions on Graphics (TOG), 41(4):1–12, 2022. doi:10.1145/3528223.3530067.

[8] Z. Luo, J. Cao, J. Merel, A. Winkler, J. Huang, K. Kitani, and W. Xu. Universal humanoid motion representations for physics-based control. In International Conference on Learning Representations, volume 2024, pages 56766–56782, 2024. URL https://proceedings.iclr.cc/paper_files/paper/2024/hash/fb19caf91f4966e426026685028cb73a-Abstract-Conference.html.

[9] C. Tessler, Y. Guo, O. Nabati, G. Chechik, and X. B. Peng. MaskedMimic: Unified physics-based character control through masked motion inpainting. ACM Transactions On Graphics (TOG), 43(6):1–21, 2024. doi:10.1145/3687951.

[10] Z. Zhang, H. Lu, Y. Lian, Z. Chen, Y. Liu, C. Lin, H. Xue, Z. Zeng, Z. Qi, S. Zheng, Q. Luan, J. Wang, J. Xing, H. Wang, and L. Yi. Learning athletic humanoid tennis skills from imperfect human motion data. In Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2026. URL https://arxiv.org/abs/2603.12686.

[11] Z. Luo, J. Cao, A. Winkler, K. Kitani, and W. Xu. Perpetual humanoid control for real-time simulated avatars. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 10895–10904, 2023. URL https://openaccess.thecvf.com/content/ICCV2023/html/Luo_Perpetual_Humanoid_Control_for_Real-time_Simulated_Avatars_ICCV_2023_paper.html.

[12] L. Fussell, K. Bergamin, and D. Holden. SuperTrack: Motion tracking for physically simulated characters using supervised learning. ACM Transactions on Graphics (TOG), 40(6):1–13, 2021. doi:10.1145/3478513.3480527.

[13] H. Yao, Z. Song, Y. Zhou, T. Ao, B. Chen, and L. Liu. MoConVQ: Unified physics-based motion control via scalable discrete representations. ACM Transactions on Graphics (TOG), 43(4):1–21, 2024. doi:10.1145/3658137.

[14] Y. Lei, Z. Luo, T. He, J. Cao, G. Shi, and K. Kitani. Scalable humanoid whole-body control via differentiable neural network dynamics. In ICLR 2025 Workshop on World Models: Understanding, Modelling and Scaling, 2025. URL https://openreview.net/pdf/b3031990328dd52267a571b265c15328bf6d6120.pdf.

[15] D. Hafner, T. Lillicrap, J. Ba, and M. Norouzi. Dream to control: Learning behaviors by latent imagination. In International Conference on Learning Representations, 2020. URL https://openreview.net/forum?id=S1lOTC4tDS.

[16] D. Hafner, J. Pasukonis, J. Ba, and T. Lillicrap. Mastering diverse control tasks through world models. Nature, 640(8059):647–653, 2025. doi:10.1038/s41586-025-08744-2.

[17] N. Hansen, X. Wang, and H. Su. Temporal difference learning for model predictive control. In K. Chaudhuri, S. Jegelka, L. Song, C. Szepesvari, G. Niu, and S. Sabato, editors, Proceedings of the 39th International Conference on Machine Learning, volume 162 of Proceedings of Machine Learning Research, pages 8387–8406. PMLR, 17–23 Jul 2022. URL https://proceedings.mlr.press/v162/hansen22a.html.

[18] P. Wu, A. Escontrela, D. Hafner, K. Goldberg, and P. Abbeel. DayDreamer: World models for physical robot learning. In Proceedings of The 6th Conference on Robot Learning, volume 205 of Proceedings of Machine Learning Research, pages 2226–2240. PMLR, 2023. URL https://proceedings.mlr.press/v205/wu23c.html.

[19] J. Xu, V. Makoviychuk, Y. Narang, F. Ramos, W. Matusik, A. Garg, and M. Macklin. Accelerated policy learning with parallel differentiable simulation. In International Conference on Learning Representations, 2022. URL https://openreview.net/forum?id=ZSKRQMvttc.

[20] Y. Song, S. Kim, and D. Scaramuzza. Learning quadruped locomotion using differentiable simulation. In Proceedings of The 8th Conference on Robot Learning, volume 270 of Proceedings of Machine Learning Research, pages 258–271. PMLR, 2025. URL https://proceedings.mlr.press/v270/song25a.html.

[21] C. Li, A. Krause, and M. Hutter. Robotic world model: A neural network simulator for robust policy optimization in robotics. arXiv preprint arXiv:2501.10100, 2025. URL https://arxiv.org/abs/2501.10100. Presented at the NeurIPS 2025 Workshop on Embodied World Models for Decision Making.

[22] C. Li, A. Krause, and M. Hutter. Uncertainty-aware robotic world model makes offline model-based reinforcement learning work on real robots. arXiv preprint arXiv:2504.16680, 2025. URL https://arxiv.org/abs/2504.16680. Presented at the 2nd Workshop on World Models at ICLR 2026.

[23] R. S. Sutton. Dyna, an integrated architecture for learning, planning, and reacting. ACM SIGART Bulletin, 2(4):160–163, 1991. doi:10.1145/122344.122377.

[24] M. Janner, J. Fu, M. Zhang, and S. Levine. When to trust your model: Model-based policy optimization. In Advances in Neural Information Processing Systems, volume 32, 2019. URL https://papers.nips.cc/paper_files/paper/2019/hash/5faf461eff3099671ad63c6f3f094f7f-Abstract.html.

[25] J. Schulman, P. Moritz, S. Levine, M. I. Jordan, and P. Abbeel. High-dimensional continuous control using generalized advantage estimation. In International Conference on Learning Representations, 2016. URL https://arxiv.org/abs/1506.02438.

[26] E. Todorov, T. Erez, and Y. Tassa. MuJoCo: A physics engine for model-based control. In IEEE/RSJ International Conference on Intelligent Robots and Systems, pages 5026–5033, 2012.

[27] Bones Studio. BONES-SEED: Skeletal everyday embodiment dataset, 2026. URL https://huggingface.co/datasets/bones-studio/seed.

[28] F. G. Harvey, M. Yurick, D. Nowrouzezahrai, and C. Pal. Robust motion in-betweening. ACM Transactions on Graphics (Proceedings of ACM SIGGRAPH), 39(4):60:1–60:12, 2020. doi: 10.1145/3386569.3392480.

附录 A 具体设定：观测、动作、奖励与仿真上下文

本附录给出第 3.1 节 POMDP 中共享空间的具体定义。动作跟踪接口沿用 BeyondMimic [3] 的形式；我们的改动在相应位置说明。

观测。 本体感知观测 o_t 包括相对于默认姿态的关节位置 $q - q^0$、关节速度 $\dot{q}$、惯性测量单元（IMU）提供的基座角速度、基座坐标系中的投影重力，以及上一时刻的动作 a_{t-1}（表 A.1）。策略接收最近 10 帧观测。

观测项	维度	噪声 η_t	单位
关节位置 $q - q^0$	29	$\mathcal{U}[-0.01, 0.01]$	rad
关节速度 $\dot{q}$	29	$\mathcal{U}[-0.5, 0.5]$	rad/s
基座角速度（IMU）	3	$\mathcal{U}[-0.2, 0.2]$	rad/s
投影重力	3	$\mathcal{U}[-0.05, 0.05]$	—
上一时刻动作 a_{t-1}	29	—	—

表 A.1：本体感知观测 o_t。 噪声列给出各维度的传感器噪声 $\eta_t \sim \rho_\eta$。

目标。 对动作跟踪接口，目标 g_t 从参考动作中读取。与 BeyondMimic [3] 使用单帧目标不同，我们让编码器以包含 $K = 10$ 帧的未来参考序列为条件。其他目标接口将 g_t 替换为各自的指令表示，例如目标速度指令（附录 B）。

动作。 动作 a_t 映射为围绕默认姿态 q^0 的关节设定值 $q^{\mathrm{sp}} = \alpha a_t + q^0$。沿用 BeyondMimic 的做法，由于 PD 增益较低，这一设定值实际充当关节力矩的代理量，而非期望位置。

奖励。 我们采用 BeyondMimic 的动作跟踪奖励（表 A.2），但移除其中的自碰撞惩罚。该惩罚用于防止随机策略钻奖励函数的空子：当参考动作使两个刚体彼此接近却不接触时，让它们相互压紧能够抑制动作噪声，从而提高速度跟踪奖励。我们的策略在想象滚动展开中是确定性的（第 3.3 节），因此这种行为无法获利，也就不再需要该惩罚项。关节限位惩罚的权重由 -10 降至 -2。

奖励项	公式	权重
任务：跟踪		
刚体位置	$\exp\left(-\frac{1}{\lvert\mathcal{T}\rvert}\sum_{b\in\mathcal{T}}\lVert p_b^{\mathrm{des}} - p_b\rVert^2/0.3^2\right)$	1.0
刚体姿态	$\exp\left(-\frac{1}{\lvert\mathcal{T}\rvert}\sum_{b\in\mathcal{T}}\lVert\log(R_b^{\mathrm{des}}R_b^\top)\rVert^2/0.4^2\right)$	1.0
刚体线速度	$\exp\left(-\frac{1}{\lvert\mathcal{T}\rvert}\sum_{b\in\mathcal{T}}\lVert v_b^{\mathrm{des}} - v_b\rVert^2/1.0^2\right)$	1.0
刚体角速度	$\exp\left(-\frac{1}{\lvert\mathcal{T}\rvert}\sum_{b\in\mathcal{T}}\lVert\omega_b^{\mathrm{des}} - \omega_b\rVert^2/3.14^2\right)$	1.0
根刚体位置	$\exp\left(-\lVert p_{\mathrm{root}}^{\mathrm{des}} - p_{\mathrm{root}}\rVert^2/0.3^2\right)$	0.5
根刚体姿态	$\exp\left(-\lVert\log(R_{\mathrm{root}}^{\mathrm{des}}R_{\mathrm{root}}^\top)\rVert^2/0.4^2\right)$	0.5
正则项		
动作平滑性	$\lVert a_t - a_{t-1}\rVert^2$	−0.1
关节限位	$\sum_j[\max(0, q_j - q_j^{\max}) + \max(0, q_j^{\min} - q_j)]$	−2

表 A.2：动作跟踪接口的奖励。 采用 BeyondMimic [3] 的设定，移除自碰撞惩罚，并将关节限位权重由 -10 降至 -2（第 3.3 节）。$\mathcal{T}$ 是被跟踪刚体的集合。

终止。 当根刚体相对参考动作的高度或倾斜偏差超过阈值时，回合终止，即 $|e_{p,z}| > 0.25\,\mathrm{m}$ 或 $e_{\mathrm{tilt}} > 0.8$。倾斜误差 e_{tilt} 是重力方向分别在参考根坐标系和机器人根（骨盆）坐标系中表示时，其 z 分量之差的绝对值。对于直立参考姿态，倾斜约 78° 时 e_{tilt} 达到 0.8。与 BeyondMimic 不同，我们不因末端执行器偏差而终止回合。

仿真上下文与域随机化。 每回合的仿真上下文 ξ 汇集输入世界模型的域随机化参数（第 3.2 节），具体见表 A.3。我们省略了 BeyondMimic 中对根刚体速度的扰动：这种推扰会引入确定性世界模型无法捕捉的状态不连续，而实验表明，仅随机化物理参数就足以实现向真实硬件的迁移。

域随机化项目	采样分布
摩擦系数	$\mu \sim \mathcal{U}[0.3, 1.2]$
关节标定偏移 [rad]	$\Delta q_j^0 \sim \mathcal{U}[-0.01, 0.01]$
躯干质心偏移 [m]	$\Delta x \sim \mathcal{U}[-0.025, 0.025]$，$\Delta y \sim \mathcal{U}[-0.05, 0.05]$，$\Delta z \sim \mathcal{U}[-0.05, 0.05]$

表 A.3：构成仿真上下文 ξ 的域随机化参数。 沿用 BeyondMimic [3]，但移除根刚体速度扰动。$\mathcal{U}[\cdot]$ 表示均匀分布。

附录 B　跨目标接口的联合训练

第 3 节中的目标 g_t 从完整参考动作中读取。下游目标接口则只规定动作的一部分，或以另一种形式描述动作。由于刚体物理过程共享，同一个动力学模型可以训练多个目标接口。我们为每个目标接口实例化一个 POMDP $\mathcal{M}_i$，例如完整参考动作目标、速度指令、末端执行器位姿或 SMPL 身体姿态目标；每个接口拥有各自的目标空间 $\mathcal{G}_i$、奖励 r_i 与终止条件 d_i，并使用各自的价值网络 V_{ψ_i} 训练。单一策略网络由各接口的目标编码器 $\mathrm{enc}_{\theta,i}$ 和共享解码器 dec_θ 构成：

$$z = \mathrm{enc}_{\theta,i}(g) \in \mathcal{Z}, \qquad a = \mathrm{dec}_\theta(z, o), \qquad g \in \mathcal{G}_i. \tag{A.1}$$

训练优化扩展后的目标 $\max_\theta \mathbb{E}_{i\sim p(\mathcal{I})}[\hat{J}_i(\theta)]$，其中 $p(\mathcal{I})$ 是目标接口集合 $\mathcal{I}$ 上的分布。因此，每个接口 i 都对应自己的策略 $a = \pi_i(o, g) := \mathrm{dec}_\theta(\mathrm{enc}_{\theta,i}(g), o)$；速度编码器还接收观测历史的特征（表 A.4）。每个 $\hat{J}_i$ 都采用式（2）的目标形式，将其中的 π_θ 替换为 π_i，并使用 $\mathcal{M}_i$ 的奖励、终止条件和价值网络 V_{ψ_i}。所有接口都通过同一个动力学模型 f_ω 训练，无须为各接口重新训练动力学模型。

根据所用奖励，下游接口通过蒸馏或强化学习训练。蒸馏使用动作跟踪奖励（第 3.3 节），指令从参考动作中读取；奖励梯度据此训练该接口，使其能够根据这一指令复现参考动作。强化学习则直接通过世界模型优化接口自身的任务奖励，例如速度跟踪奖励。在下游接口的滚动展开中，回报梯度穿过共享解码器传向该接口的编码器，但停止对解码器权重的梯度传播；解码器仍由动作跟踪目标训练。第 4.5 节采用强化学习训练的速度编码器，还在使用参考指令的滚动展开中加入潜在对齐损失，使其潜在表示靠近动作编码器的潜在表示（附录 G）。

附录 C　网络结构

表 A.4 给出第 3.2 节的世界模型动力学网络，以及附录 B 中的策略网络与价值网络。

网络	输入	输出	结构
动力学 f_ω	$\hat{s}_t, a_t, \xi$	$\hat{s}_{t+1}$	MLP (2048, 2048, 2048)
动作编码器 $\mathrm{enc}_{\theta,\mathrm{motion}}$	$K = 10$ 帧未来参考	z	MLP (2048, 1024, 512, 256)
速度编码器 $\mathrm{enc}_{\theta,\mathrm{vel}}$（附录 G）	归一化指令 (v_x, v_y, ω_z)、最近 10 帧 o 的特征	z	MLP (256, 256)
共享解码器 dec_θ	z、最近 10 帧 o	a_t	MLP (2048, 1024, 512, 256)
价值网络 V_{ψ_i}	$\hat{s}_t, g_t, \xi$	标量	MLP (256, 128)；每个接口一个价值网络

表 A.4：世界模型、策略网络与价值网络。 MLP 表示多层感知机，括号中为各隐藏层的宽度。潜在向量 z 为 32 维，由 tanh 限定取值范围。

附录 D 训练循环与超参数

D.1 算法

算法 A.1 概括第 3.1 节的 SuperMimic 训练循环，其中三个步骤与图 2 的三个面板一一对应。

算法 A.1：SuperMimic 训练。 ω 和 θ 在每次迭代中均更新；仅在策略的反向传播过程中固定 ω（停止其梯度）。对于下游接口，$\hat{J}_i$ 只更新该接口的编码器 $\mathrm{enc}_{\theta,i}$。

输入： 世界模型 f_ω；接口 $\{\mathcal{M}_i\}_{i\in\mathcal{I}}$ 共享的策略 π_θ；经验回放缓冲区 $\mathcal{B}$。

1. 对每次迭代执行：
2. **收集数据：** 在仿真中为 π_θ 加入动作噪声后滚动展开；将状态转移存入 $\mathcal{B}$，替换最旧的数据。
3. 按基于回报的采样方式选择重置起点（附录 D.1）。
4. **拟合世界模型：** 从 $\mathcal{B}$ 采样记录的 k 步窗口，在记录的动作上自回归展开 f_ω，并更新 $\omega \leftarrow \omega - \alpha_\omega \nabla_\omega L_{\mathrm{WM}}$（式（1））。
5. **改进策略：** 采样接口 $i \sim p(\mathcal{I})$，并从 $\mathcal{B}$ 采样起始状态。
6. 通过固定的 f_ω，按当前策略进行 H 步想象滚动展开：$\hat{s}_{t+1} = f_\omega\big(\hat{s}_t, \pi_i(\hat{o}_t + \eta_t, g_t), \xi\big)$。
7. 更新 $\theta \leftarrow \theta + \alpha_\theta \nabla_\theta \hat{J}_i$（式（2）；使用穿过 f_ω 的解析梯度和价值网络 V_{ψ_i}）。
8. 将价值网络 V_{ψ_i} 拟合到想象滚动展开的 GAE 目标（式（3））。
9. 结束本次迭代。

基于回报的重置采样。 仿真回合重置到动作库中的时间点，优先选择当前策略获得较低回报的位置。将动作时间轴划分为 1 s 的时间区间，每个区间 b 维护从该位置开始的折扣回报运行估计 G_b，并在策略自身的滚动展开中更新。重置分布混合三部分：50% 在区间上均匀采样；40% 按 $\mathrm{softmax}_b(-25 G_b / G_{\max})$ 采样，其中 $G_{\max}$ 为可达到的最大折扣回报；10% 按各区间过去的 softmax 权重成比例采样，使困难动作在学会后仍能得到一定练习。

D.2 超参数

表 A.5 给出超参数。如单 GPU 与双 GPU 运行的取值不同，则分别列出表 A.8 中两种运行所用的数值。

类别	超参数	符号	取值
世界模型	窗口长度	k	8
世界模型	优化器		Adam
世界模型	学习率	α_ω	单 GPU：2×10^{-4}；双 GPU：$\sqrt{2} \times 2 \times 10^{-4}$
世界模型	批量大小		每次更新使用 10 批，每批 2048 个窗口
世界模型	梯度裁剪		全局范数 1.0
想象与策略	想象时域	H	32
想象与策略	优化器		Adam，$\beta = (0.9, 0.95)$
想象与策略	学习率	α_θ	与 α_ω 相同
想象与策略	批量大小		每次更新 4096 条想象轨迹
想象与策略	梯度裁剪		先将全局范数裁剪至 1.0，再按元素裁剪至 0.1
想象与策略	折扣因子	γ	0.99
想象与策略	传感器噪声	$\eta_t \sim \rho_\eta$	表 A.1
价值网络	GAE 参数	λ	0.95
价值网络	优化器		Adam
价值网络	学习率		与 α_ω 相同
价值网络	梯度裁剪		全局范数 1.0
价值网络	每次更新的训练轮数		5 轮，每轮使用 4 个打乱顺序的小批量
数据收集	每张 GPU 的仿真环境数		4096
数据收集	动作噪声	$\epsilon_t \sim \rho_\epsilon$	每个动作维度独立服从 $\mathcal{N}(0, 0.1^2)$
数据收集	经验回放缓冲区大小		每个环境 1000 步
调度	更新与数据之比		0.4
调度	每次世界模型更新对应的策略更新次数		1
调度	学习率调度		在 250,000 次迭代内余弦衰减至初始值的 0.03 倍，此后保持不变
调度	训练长度		320,000 次迭代
调度	多 GPU		数据并行；对各 GPU 梯度求平均

表 A.5：SuperMimic 超参数。

奖励项	公式	权重
任务：速度跟踪		
线速度	$\exp\left(-\lVert v_{xy} - v_{xy}^{\mathrm{cmd}}\rVert^2 / 0.5^2\right)$	2.0
偏航角速度	$\exp\left(-(\omega_z - \omega_z^{\mathrm{cmd}})^2 / 0.5\right)$	2.0
正则项		
动作平滑性	$\lVert a_t - a_{t-1}\rVert^2$	−0.3
关节限位	$\sum_j [\max(0, q_j - q_j^{\max}) + \max(0, q_j^{\min} - q_j)]$	−2
躯干侧倾	$\sin^2 \phi_{\mathrm{torso}}$	−4
躯干横滚与俯仰角速度	$\omega_{\mathrm{roll}}^2 + \omega_{\mathrm{pitch}}^2$	−0.05
终止：跌倒	$h_{\mathrm{root}} < 0.35\,\mathrm{m}$ 或 $1 + u_z > 0.7$	

表 A.6：训练强化学习编码器所用的速度跟踪奖励和终止条件。 v_{xy} 是航向坐标系中的根刚体平面速度，ω_z 是世界坐标系中的偏航角速度，$(v_{xy}^{\mathrm{cmd}}, \omega_z^{\mathrm{cmd}})$ 是指令。ϕ_{torso} 是躯干 z 轴的侧倾角（不惩罚前倾），ω_{roll} 与 ω_{pitch} 是躯干的横滚和俯仰角速度，均在航向坐标系中表示。h_{root} 是根刚体高度，u_z 是根坐标系中单位重力方向的 z 分量；因此，直立时 $1 + u_z = 0$，倒置时为 2，倾斜条件在约 73° 时触发。本表及表 A.2 中的每一项都乘以控制周期 $\Delta t = 0.02\,\mathrm{s}$。

附录 E　动作数据筛选

我们使用公开的 BONES-SEED 动作集 [27] 训练，该数据集已重定向到 G1。原始版本包含 142,220 个片段，但许多动作需要机器人无法利用的地形或物体（楼梯、箱子、梯子、椅子），或包含重定向伪影，导致它们无法由在平地上独立站立的人形机器人执行。我们分两轮移除这些片段，最终保留 129,514 个片段（表 A.7）。

阶段	片段数
原始 BONES-SEED（G1 重定向）	142,220
名称筛选后	129,667
可行性筛选后	129,514

表 A.7：BONES-SEED 在筛选前及各轮筛选后的片段数量。

名称筛选。 每个片段均按动作命名。若名称包含表示与机器人无法利用的地形或物体接触的词语，则移除该片段，例如 stair（楼梯）、ladder（梯子）、box（箱子）、chair（椅子）、sit（坐下）、climb（攀爬）、jump off 50cm（从 50 cm 高处跳下）和 look over fence（越过围栏张望）。这一轮筛选采用 SONIC 已发布的数据处理代码 [1] 中的关键词表，并补充了其中遗漏的少量词语，共移除 12,553 个片段。

可行性筛选。 名称筛选会漏掉名称未暴露问题的片段，例如一段走上箱子的动作。我们对每个动作执行 MuJoCo 正向运动学，根据得到的刚体连杆和足部几何体轨迹进行标记。令 $z_{\min}(t) = \min_b z_b(t)$ 表示时刻 t 最低刚体连杆的高度，地面位于 $z = 0$：

- **高处支撑。** $z_{\min}$ 连续至少 0.6 s 高于 0.20 m，表明动作站在箱子上或正在爬箱子。
- **穿透地面。** $z_{\min}$ 低于 $-0.12\,\mathrm{m}$，或在片段超过 80% 的时间内低于 $-0.08\,\mathrm{m}$，表明错误的重定向使腿部穿过地面。
- **双脚悬空。** 在骨盆保持直立并处于站立高度、身体几乎静止的同时，双脚连续至少 0.5 s 高于地面 0.02 m 以上。此距离由 MuJoCo 的精确几何体到平面距离（`mj_geomDistance`）计算，使用足部碰撞几何体，而非以连杆原点近似。在没有外部支撑时，人形机器人不可能在静止站立的同时让双脚离地；因此，无论原因是低矮平台、重定向悬浮，还是缓慢升高，这种动作在平地上都不可行。静止判定条件会排除弹道式跳跃。正常触地站姿的距离为 $-0.004 \pm 0.004\,\mathrm{m}$，因此 0.02 m 阈值与地面相隔数个标准差 σ。

这一轮进一步移除 153 个片段。所有阈值均针对 50 Hz 的 G1 重定向数据调整。

附录 F 评估

F.1 基准指标

我们在相同的筛选后 BONES-SEED 训练集基准上评估 SONIC 和 SuperMimic，共评测 129,514 个动作。对于 SONIC，评估其已发布检查点及 v1.1 检查点 [1]。每个动作从首帧开始播放一次，所有策略使用相同仿真条件：足部摩擦系数为 1.0，不使用域随机化或观测噪声，物理过程是确定性的。每个策略使用自身的执行器增益与动作缩放，并接收按其训练环境方式构造的观测。如果滚动展开触发 SuperMimic 的训练终止条件（附录 A），就将该动作记为失败。SONIC 自身的成功判据在根刚体或末端执行器高度偏差超过 0.25 m 时将动作判为失败，不含姿态项 [1]。

F.2 失败动作

表 A.8 按动作组统计失败数。SONIC 在若干组中全部失败：44 个翻转动作、22 个侧滚动作，以及一套舞蹈中的全部 8 个动作；此外，它在 24 个立定跳远动作中的 15 个上失败。其 v1.1 检查点共有 239 个动作失败，包括相同的翻转与舞蹈动作，以及 22 个侧滚中的 19 个。单 GPU 训练 3 h 后，SuperMimic 的失败集中在少量困难动作组中：表 A.8 前五组共 195 个动作，包含其 25 个失败中的 14 个。没有任何一组中它的失败数多于 SONIC。双 GPU 训练 9.8 h 后，SuperMimic 无一失败。图 A.1 给出训练过程中的失败数。这些基准动作对两种方法而言均为训练动作，因此失败数衡量的是策略对这些训练动作的覆盖完整程度，而非对新动作的泛化能力。

动作组（动作数）	SONIC	SuperMimic：1 GPU × 3 h	SuperMimic：2 GPUs × 9.8 h
侧滚（22）	**22**	2	0
翻转：360°、180°、90°（44）	**44**	1	0
fire-in-the-hole 转身动作（20）	3	3	0
双腿交叉（10）	9	0	0
躺下、休息与起身（99）	28	8	0
立定跳远（24）	15	0	0
一套舞蹈动作（8）	**8**	0	0
其他所有动作（129,287）	50	11	0
总计（129,514）	179	25	0

表 A.8：筛选后 BONES-SEED 训练集基准中各动作组的失败数量。 SONIC 使用其已发布检查点。粗体表示该策略在该组所有动作上均失败。

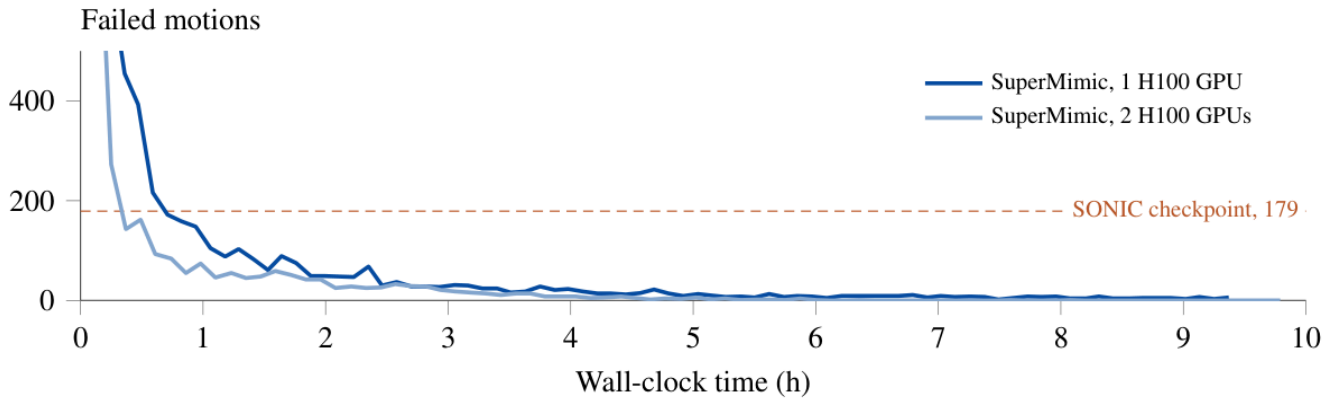


图 A.1：在筛选后 BONES-SEED 训练集基准上，训练过程中的失败动作数。 对图 3(a) 中的运行每隔 4000 次迭代评估一个检查点。SONIC 使用其已发布检查点。

F.3 实验协议

图 3。 SuperMimic 在筛选后的 BONES-SEED 数据集上训练（附录 E）。图 3(b, c) 的数据集时长扫描使用 1、7、40 和 264 h 的子集。

附录 G 速度指令任务

G.1 训练设置

第 4.5 节中的速度编码器将指令 (v_x, v_y, ω_z) 和最近 10 帧 o 的特征映射到共享潜在空间。

每个编码器在各自独立的运行中从头训练，与动作跟踪接口联合训练 100,000 次迭代。两次运行均使用从 LAFAN1 和 BONES-SEED 中筛选出的行走与跑步动作库。4096 个仿真环境的一半，以及每个想象批量的一半，使用速度接口，因此 $p(\mathcal{I})$ 为均匀分布。与算法 A.1 每次更新只采样一个接口不同，这里每个想象批量都混合两种接口。

指令。 指令 $g_t = (v_x, v_y, \omega_z)$ 由航向坐标系（仅包含偏航）中的目标根刚体平面速度，以及世界坐标系中的目标偏航角速度拼接而成。参考指令是在参考动作的航向坐标系中，对参考根刚体速度取以当前帧为中心的 25 帧均值。对于强化学习编码器，每个环境在每次重置和每隔 250 个控制步（5 s）时，重新采样指令来源：以 0.5 的概率，在每一步从参考片段读取指令；否则保持一个均匀采样的指令，其范围为 $v_x \in [-1.5, 2]\,\mathrm{m/s}$、$v_y \in [-1.32, 1.32]\,\mathrm{m/s}$、$\omega_z \in [-3.35, 3.35]\,\mathrm{rad/s}$，并以 0.1 的概率将其置零（站立）。

编码器。 对于使用参考指令的滚动展开，使用权重为 0.1 的均方误差损失，将速度潜在向量拉向同一步动作编码器的潜在向量，同时停止对动作潜在向量的梯度传播。

滚动展开、奖励与终止。 每个接口的想象滚动展开，都从该接口对应仿真环境记录的状态开始。强化学习编码器的速度滚动展开使用速度跟踪奖励，以及仅在跌倒时终止的条件（表 A.6）；蒸馏基线则使用附录 A 的动作跟踪奖励与终止条件。

G.2 阶跃测试

协议。 从站立状态开始，策略接收持续 5 s 的固定指令，每个指令测试四次。相对稳态误差定义为最后 2 s 内平均速度误差的范数除以指令的范数，其中根刚体速度在航向坐标系中测量。每个指令的结果取未跌倒试验的中位数。672 个阶跃响应对应三个平面上各一个 15×15 网格，覆盖上述均匀指令范围，并去掉站立指令。图 7 中大于 0.9 的误差均按 0.9 绘制；四次试验全部跌倒的策略也画在该上限处。

结果。 在 672 个阶跃响应中，强化学习编码器在 650 个上的误差更低，蒸馏编码器在 15 个上的误差更低。两者相对误差的中位数分别为 0.16 和 0.49。蒸馏方法在七个指令的所有试验中均跌倒，这些指令都将平移与至少 2.8 rad/s 的转向相结合，而动作库在该区域几乎没有数据。每个策略仅使用一个训练随机种子。